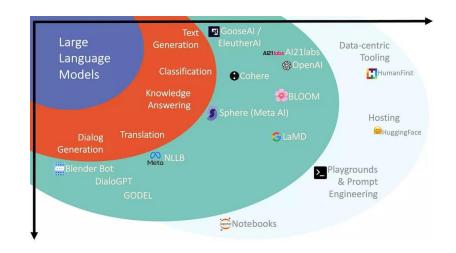
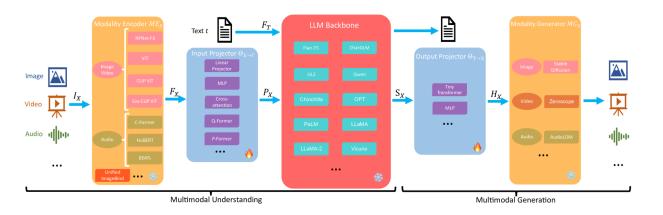
AI 실전 5주차

LLM을 개조 해볼까? LLM 파인튜닝

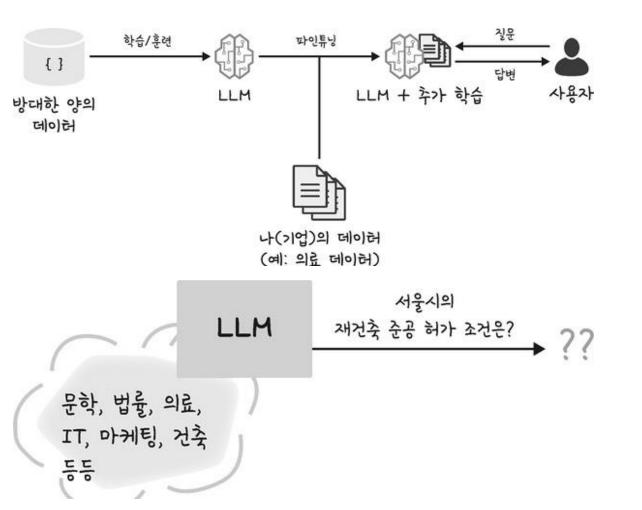
LLM 생태계는?





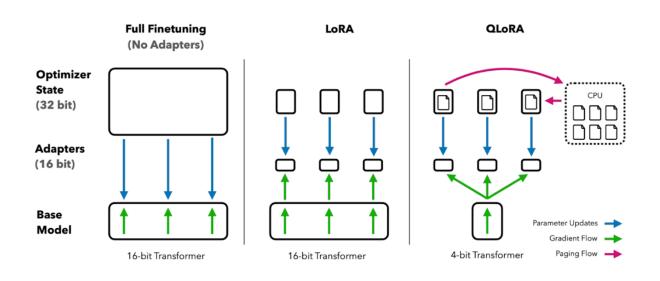
- Transformer 구조를 활용하여 언어 분류를 넘어서 생성형 모델로 발전 진행중에 있음.
 - 생성의 분야는 번역, 텍스트 생성, 분류 등등 여러 분야 확장
- 질문에 대한 대답을 이해하기 위해 여러 데이터들을 넣어서 학습하는 멀티모달 형식
 - 사진, 영상, 음성 등 입력과 출력을 함.

파인튜닝 필요한 이유



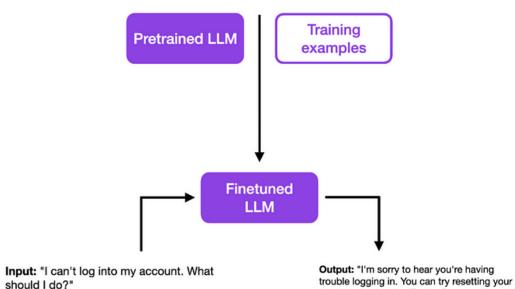
- LLM 모델로는 모든 대답을 하겠 금 생성하지만, 모든 분야를 정 확하게 대답할 수 없음.
- 다양한 기업에서 특정한 데이터 로 학습하여 결과를 좋게, 새롭 게 만듬.
 - Ex) ChatGPT-4.5 문제 해결능력은 기존보다 떨어졌으나, 문해력은 더 좋은 모델

파인튜닝의 핵심!



- 빨리 파라미터 수정하 고
- 빨리 학습하고
- 적게 리소스 먹는것!

SFT Trainer



password using the 'Forgot Password' option

on the login page.

• 특정 도메인에 맞추어 LLM 학 습하는 것

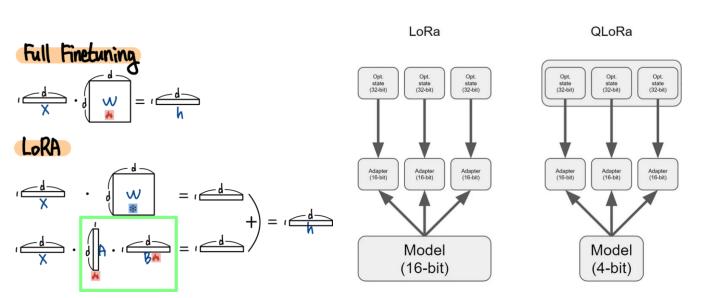
Trainer vs SFT Trainer

Feature	SFTTrainer Trainer (Supervised fine-tuning of pre-trained models)		
Purpose	General –purpose training from scratch	Supervised fine-tuning of pre-trained mo dels	
Customization	Highly customizable	Simpler interface with fewer options	
Training workflow	Handles complex workflow	Streamlined workflow	
Data requirements	Large datasets	Smaller datasets	
Memory Usage	Higher	Lower with PEFT and packing optimizations	
Training speed	Slower	Faster with smalller datasets and shorter times	

Full fine tuning

- 모든 모델의 레이어들을 파라 미터 수정(학습)하는 것.
 - 모든 레이어를 업데이트 해야하 니 속도가 느리다!
 - 계산해야하는 크기가 커서 학습할 때 많은 리소스 필요함!

PEFT (LORA, QLORA)



- 특정 부분만 파라미터 수정 하는 방식
- Q 붙은건 양자화를 의미
 - QLORA가 자원을 적게 사용

DPO(Direct Preference Optimization)

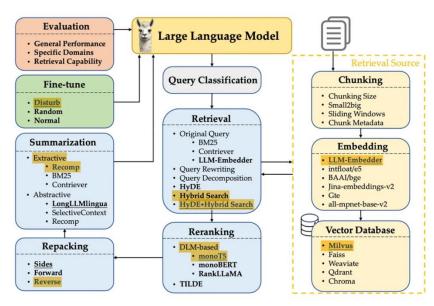


Figure 1: Retrieval-augmented generation workflow. This study investigates the contribution of each component and provides insights into optimal RAG practices through extensive experimentation. The optional methods considered for each component are indicated in **bold** fonts, while the methods <u>underlined</u> indicate the default choice for individual modules. The methods indicated in blue font denote the best-performing selections identified empirically.

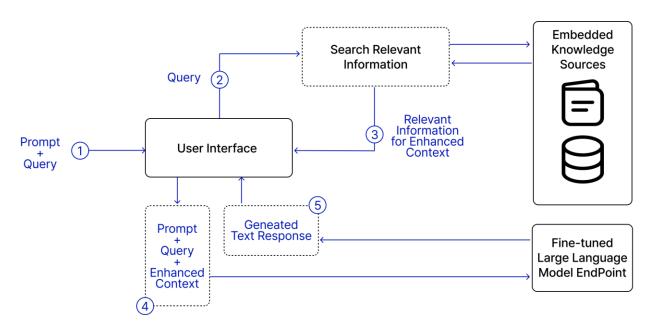
- 사용자의 희망하는 답변을 응답할 수 있게 하는 것.
- 정답에 가깝게 생성하는 주 목 적이 아닌 사용자의 원하는 답 변을 생성하는 것.
- 답변을 여러가지 데이터가 필요!

SFT vs DPO

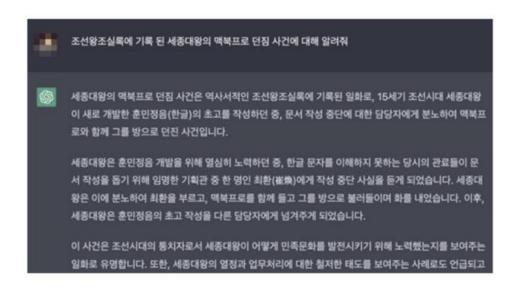
특징 학습 목적 데이터 형식 손실 함수 출력 성격 적용 사례 SFT 정답 학습 Prompt-Response 데이터 Cross-Entropy Loss 데이터 의존적 새로운 Task 학습

DPO
사용자 선호 학습
Prompt-Response + 선호도 비교 데이터
Log-Sigmoid Loss (Ranking Loss)
사용자 중심적
대화 품질 개선, 사용자 피드백 반영

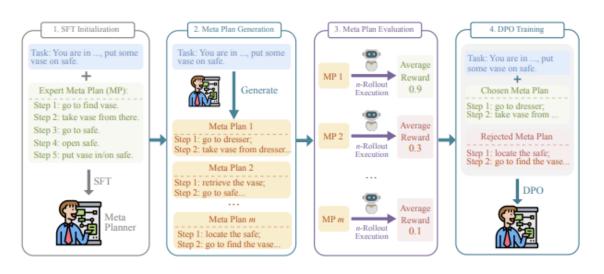
파인튜닝 할 시간이 많이 없다면?



- 외부의 데이터를 참고하여 대 답하겠금 하는 RAG 기법 사용 하자!
- 아래와 같은 문제 해결하기 위 함이다!(LLM 환격 문제 해결)



MPO(Meta Plan Optimization)



Model	w/o Exp. Guid.	ScienceWorld		ALFWorld		Average
Made		Seen	Unseen	Seen	Unseen	Average
Agent	ts w/o Training					
GPT-40 (Achiam et al., 2023)	Х	60.0	56.0	78.6	83.6	69.6
GPT-4o-mini (Achiam et al., 2023)	×	49.1	42.7	32.1	41.0	41.2
Llama-3.1-8B-Instruct (Dubey et al., 2024)	X	47.7	42.2	22.9	28.4	35.3
Qwen2.5-7B-Instruct (Yang et al., 2024a)	×	38.5	38.8	71.4	75.4	56.0
Llama-3.1-70B-Instruct (Dubey et al., 2024)	X	72.6	70.2	78.6	73.9	73.8
Llama-3.1-8B-Instruct + MPO	1	56.5	55.5	50.0	52.2	53.6
GPT-4o + MPO	/	67.3	67.8	89.3	93.3	79.4
Llama-3.1-70B-Instruct + MPO	1	80.4	79.5	85.7	86.6	83.1
Agen	ts w/ Training					
Llama-3.1-8B-Instruct + SFT (Zeng et al., 2023)	Х	65.3	57.0	79.3	71.6	68.3
Llama-3.1-8B-Instruct + ETO (Song et al., 2024b)	X	81.3	74.1	77.1	76.4	77.2
Llama-3.1-8B-Instruct + KnowAgent (Zhu et al., 2024)	✓	81.7	69.6	80.0	74.9	76.6
Llama-3.1-8B-Instruct + WKM (Qiao et al., 2024)	✓	82.1	76.5	77.1	78.2	78.5
Llama-3.1-8B-Instruct-SFT + MPO	1	70.2	65.9	80.7	81.3	74.5
Llama-3.1-8B-Instruct-ETO + MPO	/	83.4	80.8	85.0	79.1	82.1

- 에이전트의 계획 과정을 조정하기 위한 명확한 지침을 도입하고,
 에이전트의 피드백을 기반으로 지침을 구체화할 수 있는 기능을 제공.
- 사용되는 리소스, 점수를 높게 받 는다고 함!(하단 그림 참고)

실습 unsloth으로 파인튜닝

https://colab.research.google.com/github/unslothai/notebooks/blob/main/nb/Llama3.2_(1B_and_3B)-Conversational.ipynb#scrollTo=FOYXyGpVCK-V

패키지 설치

```
%%capture
import os
if "COLAB_" not in "".join(os.environ.keys()):
    !pip install unsloth
else:
    # Do this only in Colab notebooks! Otherwise use pip install unsloth
    !pip install --no-deps bitsandbytes accelerate xformers==0.0.29.post3 peft trl
triton cut_cross_entropy unsloth_zoo
    !pip install sentencepiece protobuf "datasets>=3.4.1" huggingface_hub hf_transfer
    !pip install --no-deps unslot
```

모델 불러오기

```
from unsloth import FastLanguageModel
import torch
max_seq_length = 2048 # Choose any! We auto support RoPE Scaling internally!
dtype = None # None for auto detection. Float16 for Tesla T4, V100, Bfloat16 for
load_in_4bit = True # Use 4bit quantization to reduce memory usage. Can be False.
    "unsloth/Meta-Llama-3.1-8B-bnb-4bit", # Llama-3.1 2x faster
    "unsloth/Meta-Llama-3.1-8B-Instruct-bnb-4bit",
    "unsloth/Meta-Llama-3.1-70B-bnb-4bit",
    "unsloth/Meta-Llama-3.1-405B-bnb-4bit", # 4bit for 405b!
    "unsloth/Mistral-Small-Instruct-2409", # Mistral 22b 2x faster!
    "unsloth/mistral-7b-instruct-v0.3-bnb-4bit",
    "unsloth/Phi-3-medium-4k-instruct",
    "unsloth/gemma-2-9b-bnb-4bit",
    "unsloth/gemma-2-27b-bnb-4bit",
    "unsloth/Llama-3.2-1B-bnb-4bit",
    "unsloth/Llama-3.2-1B-Instruct-bnb-4bit",
    "unsloth/Llama-3.2-3B-bnb-4bit",
    "unsloth/Llama-3.2-3B-Instruct-bnb-4bit",
    "unsloth/Llama-3.3-70B-Instruct-bnb-4bit" # NEW! Llama 3.3 70B!
model, tokenizer = FastLanguageModel.from_pretrained(
    model_name = "unsloth/Llama-3.2-3B-Instruct", # or choose "unsloth/Llama-3.2-1B-
    max seg length = max seg length,
    load_in_4bit = load_in_4bit,
```

Peft 설정

모델 포멧 설정 및 데이터 불러오기

```
from unsloth.chat_templates import get_chat_template

tokenizer = get_chat_template(
    tokenizer,
    chat_template = "llama-3.1",
)

def formatting_prompts_func(examples):
    convos = examples["conversations"]
    texts = [tokenizer.apply_chat_template(convo, tokenize = False,
add_generation_prompt = False) for convo in convos]
    return { "text" : texts, }
pass

from datasets import load_dataset
dataset = load_dataset("mlabonne/FineTome-100k", split = "train")
```

```
from unsloth.chat_templates import standardize_sharegpt
dataset = standardize_sharegpt(dataset)
dataset = dataset.map(formatting_prompts_func, batched =
True,)
```

SFT Trainer 설정

```
from trl import SFTTrainer
from transformers import TrainingArguments, DataCollatorForSeg2Seg
from unsloth import is_bfloat16_supported
trainer = SFTTrainer(
   model = model,
    tokenizer = tokenizer,
   train_dataset = dataset,
   dataset text field = "text",
   max_seq_length = max_seq_length,
   data_collator = DataCollatorForSeq2Seq(tokenizer = tokenizer),
   dataset_num_proc = 2,
    packing = False, # Can make training 5x faster for short
    args = TrainingArguments(
        per_device_train_batch_size = 2,
        gradient accumulation steps = 4,
        warmup_steps = 5,
       max_steps = 60,
        learning_rate = 2e-4,
        fp16 = not is_bfloat16_supported(),
        bf16 = is_bfloat16_supported(),
        logging_steps = 1,
        optim = "adamw_8bit",
        weight_decay = 0.01,
        lr_scheduler_type = "linear",
        seed = 3407,
        output_dir = "outputs",
        report_to = "none", # Use this for WandB etc
    ),
```

데이터 전처리

```
from unsloth.chat_templates import train_on_responses_only
trainer = train_on_responses_only(
    trainer,
    instruction_part = "
<|start_header_id|>user<|end_header_id|>\n\n",
    response_part = "
<|start_header_id|>assistant<|end_header_id|>\n\n",
)
```

```
space = tokenizer(" ", add_special_tokens = False).input_ids[0]
tokenizer.decode([space if x == -100 else x for x in
trainer.train_dataset[5]["labels"]])
```

파인튜닝 시작

```
trainer_stats = trainer.train()
```

추론하기

모델 및 Iora 저장

```
model.save_pretrained("lora_model") # Local saving
tokenizer.save_pretrained("lora_model")
if False: model.save pretrained merged("model", tokenizer, save method =
"merged_16bit",)
if False: model.push_to_hub_merged("hf/model", tokenizer, save_method = "merged_16bit",
if False: model.save_pretrained_merged("model", tokenizer, save_method =
"merged_4bit",)
if False: model.push_to_hub_merged("hf/model", tokenizer, save_method = "merged_4bit",
if False:
    model.save_pretrained("model")
    tokenizer.save_pretrained("model")
if False:
    model.push_to_hub("hf/model", token = "")
    tokenizer.push_to_hub("hf/model", token = "")
```