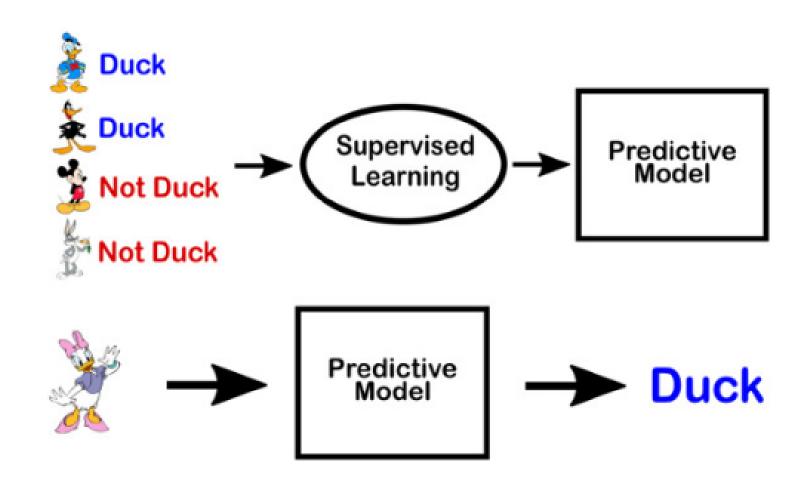
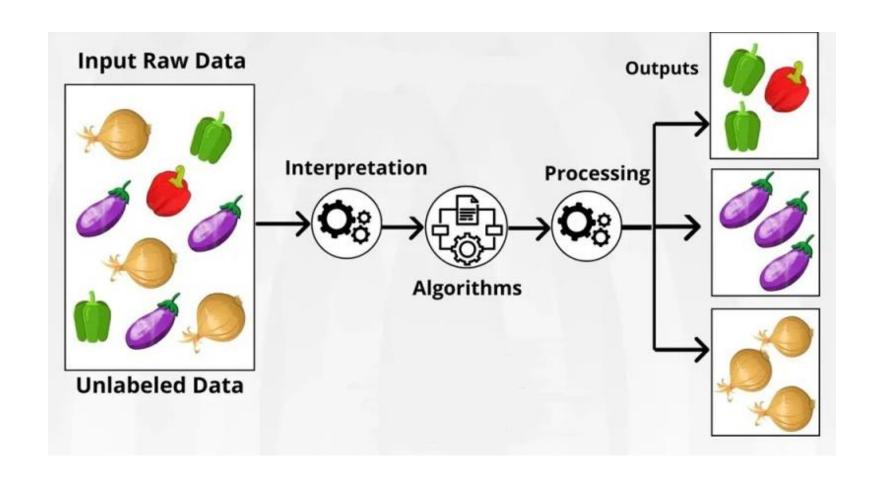
머신러닝 문제 종류



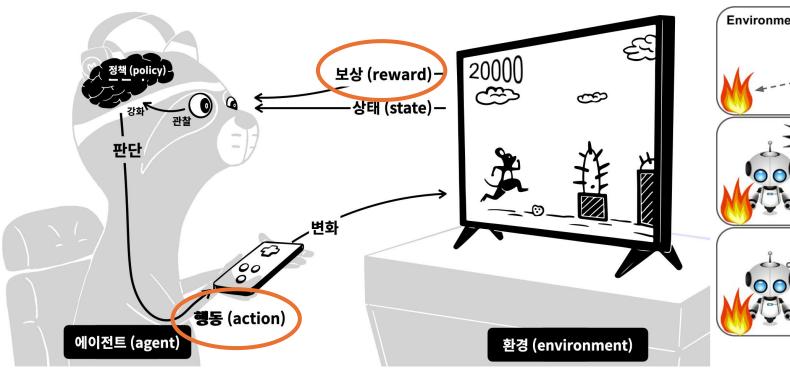
지도학습

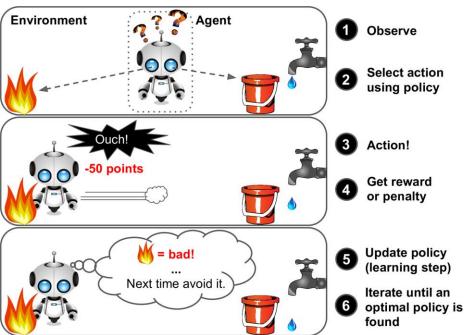


비지도 학습



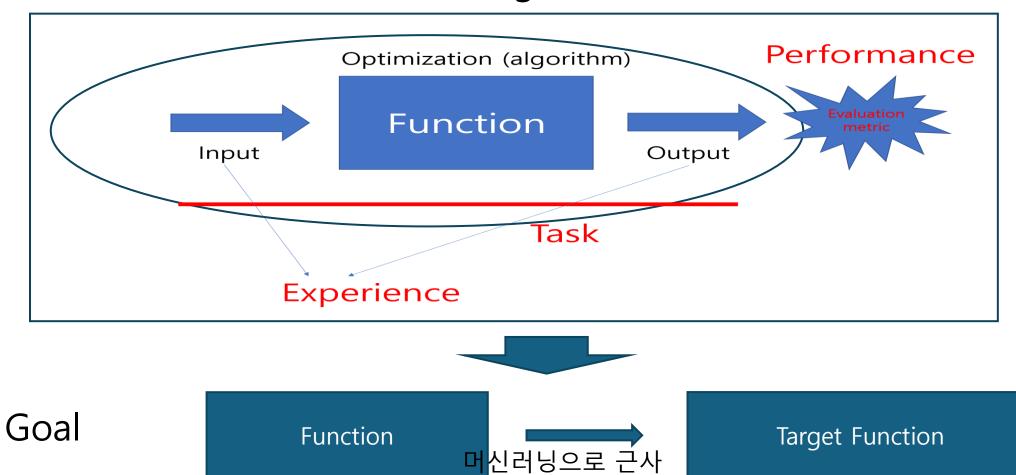
강화 학습



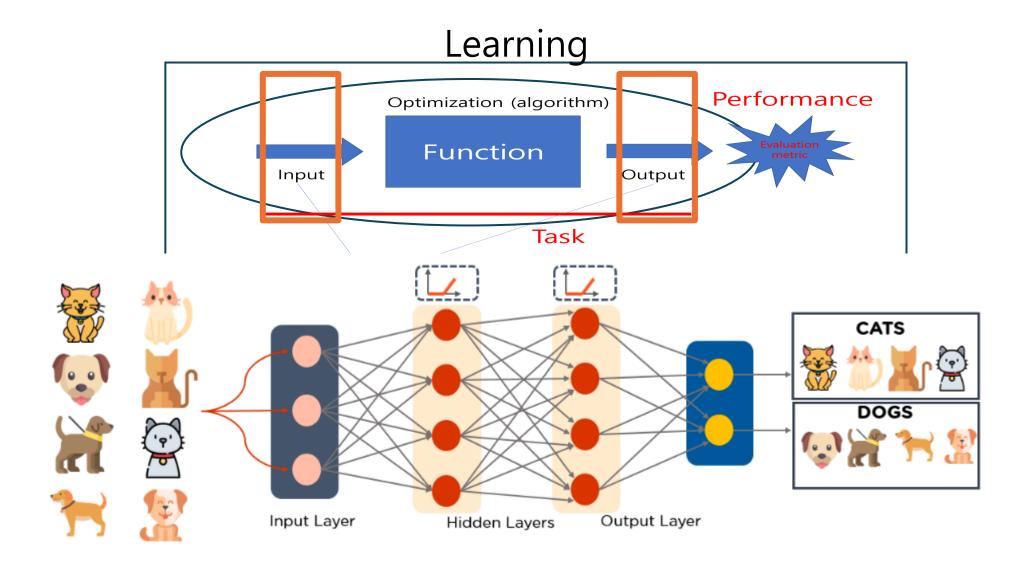


Al Goals

Learning

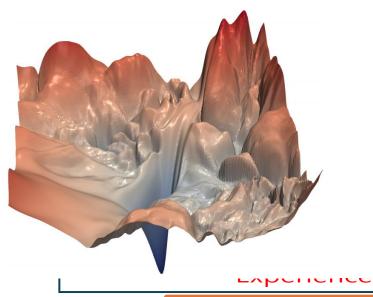


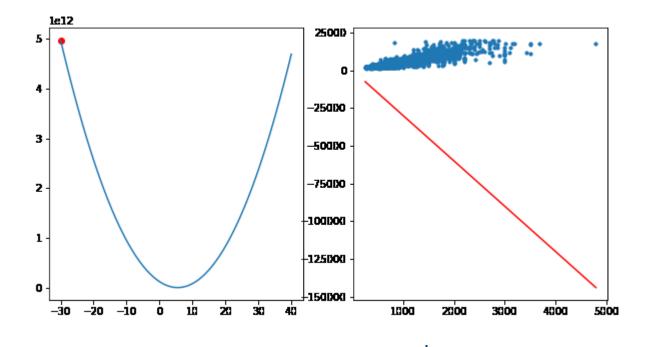
Al Goals



Al Goals 퍼셉트론, KNN, 선형회귀 결정트리 Learning ETC... Performance Optimization (algorithm) **Function** Input Dutput Task Experience Goal Target Function Function **머**신러닝으로 근**사**

Al Goals

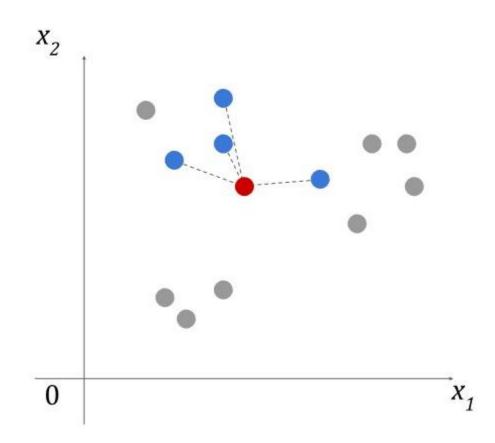




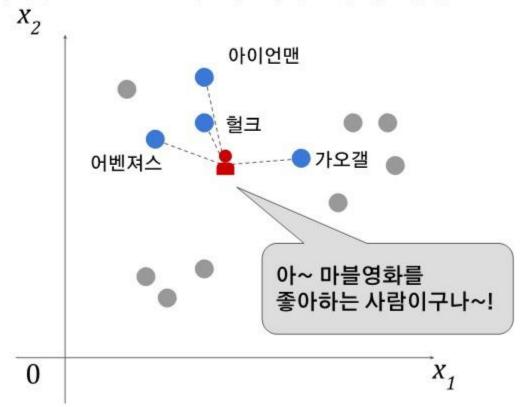
Goal

Function Target Function 머신러닝으로 근사

kNN = 가장 가까운 k개의 점



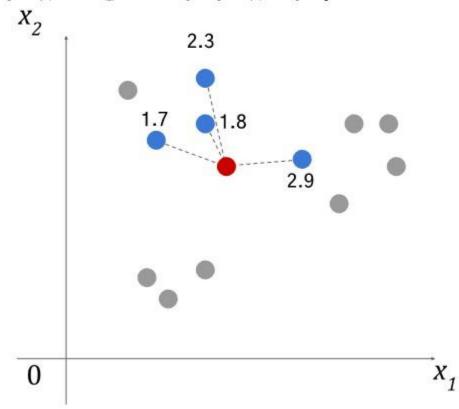
- 어떤 점의 특성을 알고 싶다면?
 - 가까이 있는 점으로부터 특성 파악 가능



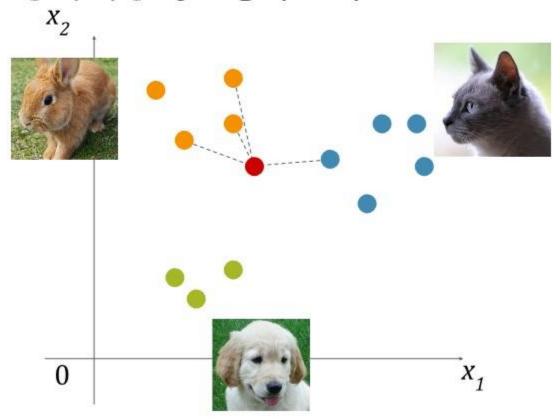
kNN의 특징

- 데이터 기반 분석 방법
- 데이터 분포를 가정하지 않음
- 회귀문제, 분류문제 등에 적용 가능

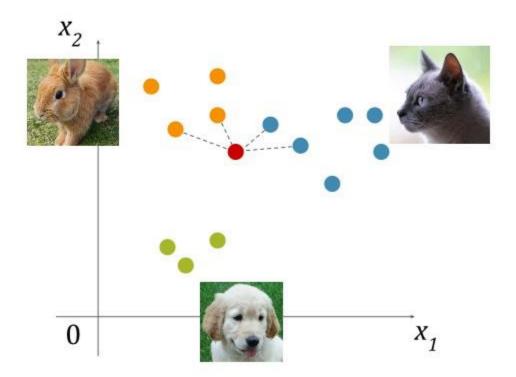
- kNN을 회귀문제에 적용 가능
 - kNN의 값을 평균 내어 값 예측



- kNN을 분류문제에 적용 가능
 - kNN 중에 가장 많은 항목 선택



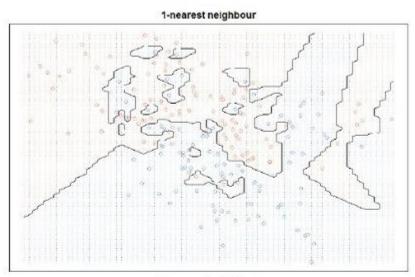
- 1등이 여럿일 경우엔?
 - 방법1. 거리에 따라 가중치 주기
 - 방법2. 단독 1등이 나올 때까지 k를 하나씩 줄이기

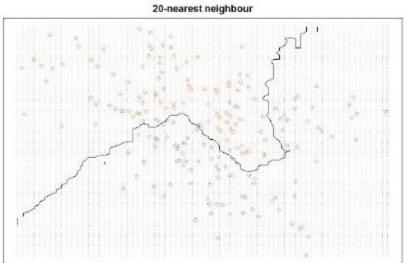


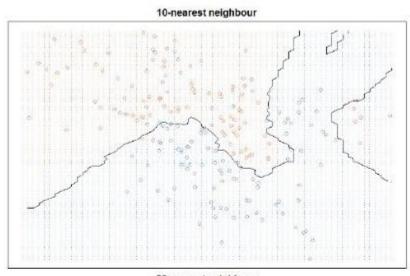
적절한 k값은?

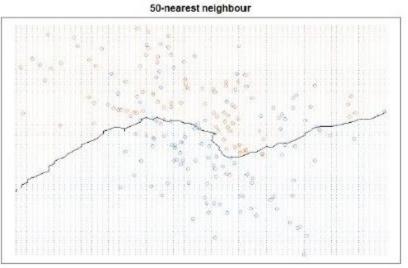
- 데이터마다 적절한 k값이 다름
 - 。 k가 낮다 → 불안정한 결과 ~ 오버피팅
 - o k가 높다 → 지나친 일반화 ~ 언더피팅

적절한 k값은?









적절한 k값은?

- k를 선택하는 방법: 가장 좋은 성능을 내는 값으로 선택
 - k의 값을 1부터 증가시켜가며 각 점들에 대해 knn으로 분류해보고 오류 계산
 - 가장 오류가 적은 k값을 선택

거리?

$$X = (x_1, x_2, \cdots, x_n)$$
$$Y = (y_1, y_2, \cdots, y_n)$$

Euclidean Distance (L2)

$$\sqrt{\sum_{i=1}^n (x_i-y_i)^2}$$

Manhattan Distance (L1)

$$\sum_{i=1}^n |x_i-y_i|$$

Cosine Distance

$$1-rac{X\cdot Y}{|X||Y|}$$



거리?

Hamming Distance (곱집합)

$$|\{i \in \{1,2,\cdots,n\}| x_i
eq y_i\}| egin{array}{c} X = (x_1,x_2,\cdots,x_n) \ Y = (y_1,y_2,\cdots,y_n) \end{array}$$

자카드거리 (집합)

$$1-rac{|X\cap Y|}{|X\cup Y|}$$
 $X=\{x_1,x_2,\cdots,x_n\} \ Y=\{y_1,y_2,\cdots,y_m\}$

kNN 장단점

- 장점
 - 쉽고 이해하기 직관적
 - 사전 학습이 필요 없다
 - 어떤 분포든 상관 없음 (비모수 방식)
 - 데이터가 많을 경우 정확도 up! up!
- 단점
 - 데이터가 많을 경우 연산량 up! up!
 - 차원 축소 등으로 계산량 감소
 - 인덱싱으로 탐색 속도 향상
 R-Tree, KD-Tree, KNN-Graph,
 LSH(Locality Sensitive Hashing), etc.
 - 차원의 저주
 - 데이터의 차원이 증가함에 따라 정확도 급하락

학습 데이터 준비

http://bit.ly/bream_smelt

데이터 합치기

```
import numpy as np

np.column_stack(([1,2,3], [4,5,6]))
```

각 독립변수 하나의 변수(X)로 합치기

```
fish_data = np.column_stack((fish_length, fish_weight))
print(fish_data[:5])
```

Y의 변수의 클래스 지정

```
# [[1] * 35 + [0] * 14]
fish_target = np.concatenate((np.ones(35), np.zeros(14)))
```

훈련세트와 테스트 데이터 나누기

```
from sklearn.model_selection import train_test_split

# random_state = 42를 지정한 이유는 똑같은 서도 = 똑같은 결과로 나옴.
train_input, test_input, train_target, test_target = train_test_split(
    fish_data, fish_target, random_state=42)
```

데이터 잘 나누어졌는지 길이 확인

```
print(train_input.shape, test_input.shape)
print(train_target.shape, test_target.shape)
```

데이터 비율 균일하게

```
train_input, test_input, train_target, test_target = train_test_split(
    fish_data, fish_target, stratify=fish_target, random_state=42)
print(test_target)
```

KNN 모델 학습 및 결과 확인

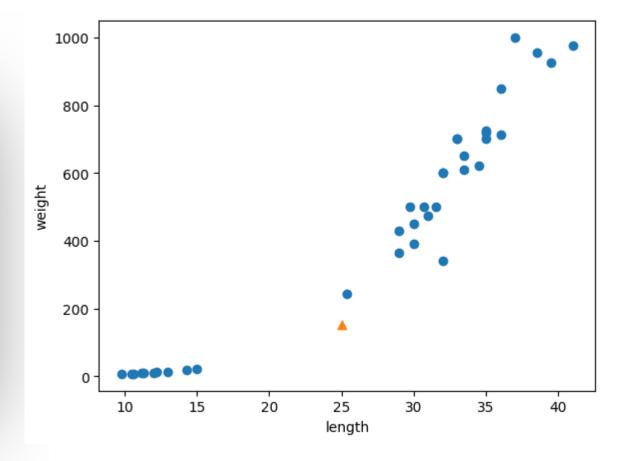
```
from sklearn.neighbors import KNeighborsClassifier
kn = KNeighborsClassifier()
kn.fit(train_input, train_target)
kn.score(test_input, test_target

print(kn.predict([[25, 150]]))
```

차트 그래프 출력

```
import matplotlib.pyplot as plt

plt.scatter(train_input[:,0], train_input[:,1])
plt.scatter(25, 150, marker='^')
plt.xlabel('length')
plt.ylabel('weight')
plt.show()
```



25, 150 데이터에서 가장 가까운 데이터

```
distances, indexes = kn.kneighbors([[25, 150]])

plt.scatter(train_input[:,0], train_input[:,1])
plt.scatter(25, 150, marker='^')
plt.scatter(train_input[indexes,0], train_input[indexes,1], marker='D')
plt.xlabel('length')
plt.ylabel('weight')
plt.show()

print(train_target[indexes])
```